



Projektportfolio

IU Internationale Hochschule

Studiengang: M.Sc. Informatik

Anforderungsdokument

Projekt Software Engineering

DLMCSPSE01_D_CF

GitHub: <https://github.com/micael92/FlowWorkbench>

Download: <https://github.com/micael92/FlowWorkbench/releases/tag/v0.1.0>

Michael Hilfer

Matrikelnummer: 3205669

Tutor: Prof. Dr. Dirk Simon

Inhaltsverzeichnis

Abbildungsverzeichnis	III
Tabellenverzeichnis	IV
1. Stakeholder.....	1
2. Anforderungen.....	3
3. Glossar	9
Literaturverzeichnis.....	10

Abbildungsverzeichnis

Abb. 1: Use-Case-Diagramm	3
---------------------------------	---

Tabellenverzeichnis

Tab. 1: Stakeholderanalyse mit Maßnahmen	2
Tab. 2: Funktionale Anforderungen	4
Tab. 3: Nichtfunktionale Anforderungen	6
Tab. 4: Wichtige projektspezifische Abkürzungen und Begriffe	9

1. Stakeholder

Die zu entwickelnde Software richtet sich an Personen, die Intrusion-Detection-System-Datensätze untersuchen und für eine weitere Nutzung im Bereich des maschinellen Lernens vorbereiten wollen. Als Ziel-/Benutzergruppe werden somit insbesondere Studierende, aber auch Forschende angesehen, die eine derartige Software im Rahmen von Forschungsarbeiten hilfreich einsetzen können. Die Software stellt eine Open-Source-Entwicklung dar, die der Allgemeinheit zur Verfügung gestellt wird, gleichzeitig jedoch für eine spezifische Zielgruppe entwickelt wird.

Für das Projekt wurde eine Stakeholderanalyse durchgeführt. Hierbei wurden Stakeholder, fördernde und gefährdende Interessen, mögliche Konfliktpotenziale, Einflüsse sowie Maßnahmen zur positiven Beeinflussung der Stakeholder ermittelt. Dabei wurden vier Stakeholder(-gruppen) identifiziert und erfasst. Die Stakeholderanalyse ist in Tabelle 1 ersichtlich.

Insgesamt hat die Stakeholderanalyse gezeigt, dass die Anzahl der Stakeholder im Vergleich zu größeren Entwicklungsprojekten gering ist. Dies ist unter anderem darauf zurückzuführen, dass das Projekt über kein finanzielles Budget verfügt, keinen beauftragenden Kunden besitzt und auf der Arbeit einer einzelnen Person basiert. Es entstehen somit keine Abhängigkeiten zu Stakeholdern mit finanziellen Interessen, Auftraggebern oder anderen Zulieferern. Insbesondere ein Stakeholder in Form eines konkreten Kunden, der finanzielle oder anderweitige Mittel für das Projekt zur Verfügung stellt, ist in diesem Projekt nicht vorhanden. Entsprechend gibt es keine Stakeholder, die aufgrund vertraglicher Verpflichtungen über ein gezieltes Stakeholdermanagement in das Projekt eingebunden werden müssen.

Tab. 1: Stakeholderanalyse mit Maßnahmen

Stakeholder	Beteiligung	fördernde Interessen	gefährdende Interessen	Konflikt-potenzial	Einfluss	Maßnahme
M. Hilfer, Student	Projektleiter Entwickler	- Erfolgreicher Projektabschluss - gute Bewertung - nützliches Tool für weitere Arbeiten	- Eingeschränkte zeitliche Kapazitäten	gering	hoch	- Strukturierte Zeitplanung - Priorisierung der Kernfunktionen
Tutor, Prüfer	Feedback, Bewertung des Projekts	- erfolgreiche Projektdurchführung - lehrreiches Projekt für den Studenten - Nachvollziehbarer SWE-Prozess	- Einhaltung Formalia	gering	hoch	- Einbindung bei Unklarheiten - Umsetzung von Hinweisen im Feedback
interessierte Studierende und Forschende	Nutzer	- hilfreiches Tool für Forschung, Hausarbeiten, Abschlussarbeiten etc.	- Nichtberücksichtigung wichtiger Nutzeranforderungen	gering	mittel	- Identifikation der wichtigsten Anforderungen der Nutzer
Entwickler von Drittanbieterbibliotheken	Stellt Softwarebibliotheken zur Verfügung	- Verbreitung eigener Bibliotheken	- Einhaltung Lizenzvorgaben	gering	gering	- Prüfung der Lizenzen vor Einbindung von Bibliotheken


Quelle: Eigene Darstellung.

2. Anforderungen

In den funktionalen Anforderungen wurden die Funktionen und Eigenschaften erfasst, die das Programm bereitstellen soll. Dazu wurden die aus Anwendersicht erforderlichen Anforderungen ermittelt und mithilfe der MoSCoW-Methode priorisiert. Zwingend umzusetzende Anforderungen wurden dabei als „Must“ klassifiziert. Anforderungen, die für die Anwendung wichtig, jedoch nicht zwingend erforderlich sind, wurden als „Should“ eingestuft. Optionale Anforderungen, deren Umsetzung nur bei ausreichenden Ressourcen erfolgt, wurden hingegen als „Could“ definiert. Für jede funktionale Anforderung wurde eine User Story ergänzt, die die Anforderungen aus Anwendersicht genauer beschreibt. Die Anforderungen sind in den Tabellen 2 und 3 aufgeführt.

Zur Visualisierung von grundlegenden Anwendungsfällen wurde das in Abbildung 1 dargestellte Use-Case-Diagramm erzeugt.

Abb. 1: Use-Case-Diagramm



Quelle: Eigene Darstellung.

Tab. 2: Funktionale Anforderungen

ID	Funktion	Beschreibung	Priorität
FA-01	CSV-Datei importieren	Der Benutzer kann einen Flow-Datensatz im CSV-Format laden.	Must
Als Benutzer möchte ich einen Flow-Datensatz im CSV-Format laden können, damit ich mir einen Überblick über die Daten verschaffen kann und ausgewählte Schritte zur Vorverarbeitung durchführen kann.			
FA-02	Datensatzinformationen anzeigen	Das System zeigt Anzahl der Zeilen, Spalten, Speichergröße, die Anzahl unendlicher und fehlender Werte an.	Must
Als Benutzer möchte ich Informationen über den geladenen Datensatz anzeigen lassen können, damit ich einen Überblick über dessen Struktur und Größe erhalte.			
FA-03	Flow-Daten anzeigen	Das System stellt die geladenen Daten als Vorschau mit 1000 Zeilen tabellarisch dar.	Must
Als Benutzer möchte ich eine Vorschau des Datensatzes in tabellarischer Form anzeigen lassen können, damit ich einzelne Datensätze und Merkmale einsehen kann.			
FA-04	Statistische Kennzahlen berechnen	Das System kann Minimum, Maximum, Mittelwert, Median und Standardabweichung eines Merkmals berechnen und anzeigen.	Must
Als Benutzer möchte ich statistische Kennzahlen für einzelne Merkmale berechnen lassen können, damit ich die Eigenschaften des Datensatzes besser beurteilen kann.			
FA-05	Merkmale entfernen	Der Benutzer kann ausgewählte Merkmale (Spalten) aus dem Datensatz entfernen.	Must
Als Benutzer möchte ich Merkmale aus dem Datensatz entfernen können, damit ich für ein ML-Modell-Training ungeeignete Merkmale entfernen kann.			
FA-06	Datensatz exportieren	Der Benutzer kann bearbeitete Datensätze exportieren.	Must

Als Benutzer möchte ich bearbeitete Datensätze exportieren können, damit die Ergebnisse außerhalb der Anwendung weiterverwendet werden können.			
FA-07	Labelverteilung anzeigen	Das System zeigt die Verteilung der Labels im Datensatz als Plot und numerisch an.	Should
Als Benutzer möchte ich mir anzeigen lassen, welche Labels im Datensatz existieren und wie oft diese vorkommen, damit ich beurteilen kann, wie die Label im Datensatz verteilt sind.			
FA-08	Daten sortieren	Der Benutzer kann die Datenvorschau nach ausgewählten Spalten sortieren.	Should
Als Benutzer möchte ich die angezeigten Daten nach ausgewählten Spalten sortieren können, damit ich bestimmte Werte leichter analysieren kann.			
FA-09	Daten filtern	Der Benutzer kann die Datenvorschau nach Labels, Protokollen und weiteren Merkmalen filtern.	Could
Als Benutzer möchte ich die Daten nach bestimmten Merkmalen filtern können, damit ich relevante Teilmengen des Datensatzes gezielt betrachten kann.			
FA-10	Korrelationsmatrix erzeugen	Das System berechnet und visualisiert Korrelationen numerischer Features.	Could
Als Benutzer möchte ich eine Korrelationsmatrix für numerische Merkmale erzeugen können, damit Zusammenhänge zwischen den Merkmalen identifiziert werden können.			
FA-11	Fehlende Werte behandeln	Der Benutzer kann NaN-Werte ersetzen oder entfernen.	Could
Als Benutzer möchte ich fehlende Werte ersetzen oder entfernen können, damit der Datensatz für weitere Analysen oder Machine-Learning-Verfahren vorbereitet werden kann.			
FA-12	Unendliche Werte behandeln	Der Benutzer kann unendliche Werte ersetzen oder entfernen.	Could

Als Benutzer möchte ich unendliche Werte ersetzen oder entfernen können, damit fehlerhafte Datensätze bereinigt werden können.			
FA-13	Train-Test-Split durchführen	Das System kann Datensätze in Trainings- und Testdaten aufteilen.	Could
Als Benutzer möchte ich einen Datensatz in Trainings- und Testdaten aufteilen können, damit dieser für Machine-Learning-Experimente verwendet werden kann.			

Quelle: Eigene Darstellung.

Neben funktionalen Anforderungen wurden auch nicht funktionale Anforderungen ermittelt und nach der MoSCoW-Methode priorisiert und zusätzlich kategorisiert. Die nichtfunktionalen Anforderungen dienen der Beschreibung von Qualitätsanforderungen für die zu entwickelnde Anwendung und sind in Tabelle 3 ersichtlich.

Tab. 3: Nichtfunktionale Anforderungen mit Erweiterung um Abnahmekriterien

ID	Kategorie	Anforderung	Abnahmekriterium	Priorität
NF-01	Benutzer-freundlichkeit	Die Anwendung soll über eine grafische Benutzeroberfläche verfügen, die von Nutzern der Zielgruppe intuitiv bedient werden kann, um einen Mehrwert gegenüber einer eigenen Lösung des Nutzers mit Hilfe von Programmierarbeit zu bieten.	Ein Testnutzer aus der Zielgruppe kann die Use Cases der Anwendung ohne Benutzerhandbuch ausführen.	Must
NF-02	Benutzer-freundlichkeit	Fehlermeldungen sollen detaillierte Informationen enthalten, so dass für Nutzer aus der Zielgruppe die Möglichkeit besteht Ursachen für den Fehler zu erkennen und ggfs. zu beheben.	Jede Fehlermeldung besteht zumindest aus einem erklärenden Satz.	Must

NF-03	Performance	Die Anwendung soll große CSV-Dateien nicht unkontrolliert in den Arbeitsspeicher laden, weil große Dateien den gesamten Arbeitsspeicher eines Systems belegen können und so zu System- und Anwendungsfehlern führen können. Die maximale Größe der verarbeitbaren Dateien wurde am Beispiel des im Anwendungskontext relevanten Datensatzes CIC-IDS2017 ausgerichtet.	Ein Import einer Datei mit einer Größe von mehr als 500 MiB wird von der Anwendung abgewiesen.	Must
NF-04	Zuverlässigkeit	Ungültige CSV-Dateien dürfen nicht zum Absturz der Anwendung führen, da fehlerhafte oder inkompatible Eingabedateien nicht ausgeschlossen werden können.	Nur CSV-Dateien können für den Import gewählt werden. Das Importieren einer korrupten CSV-Datei führt zu einer Fehlermeldung und nicht zum Programmabsturz.	Must
NF-05	Zuverlässigkeit	Fehler während der Datenverarbeitung sollen abgefangen und dem Benutzer angezeigt werden, um Fehlerursachen erkennbar zu machen.	Von der Anwendung erkannte Fehler werden mit einer Fehlermeldung quittiert und die Anwendung bleibt bedienbar.	Must
NF-06	Sicherheit	Die Anwendung soll ausschließlich lokale Dateien verarbeiten und keine Daten ohne Benutzeraktion an externe Systeme übertragen, da es hierfür keinen Bedarf gibt.	Der Programmcode enthält nur die definierten Schnittstellen zur Interaktion mit dem Dateisystem des Betriebssystems.	Must
NF-07	Sicherheit	Die Anwendung soll keine Makros, Skripte oder ausführbaren Inhalte aus importierten Dateien ausführen, da importierte Datensätze als nicht vertrauenswürdige Eingabedaten behandelt werden.	Inhalte importierter CSV-Dateien werden ausschließlich als Daten eingelesen und an keiner Stelle als Programmcode, Skript oder Betriebssystembefehl ausgeführt.	Must
NF-08	Portabilität	Die Anwendung soll unter Windows 10 und Windows 11 lauffähig sein, da beide Betriebssystemversionen als Zielplattformen für die Desktopanwendung vorgesehen sind.	Die Anwendung wird fehlerlos auf Windows 10 und 11 ausgeführt.	Must

NF-09	Verfügbarkeit	Die Anwendung soll ohne Internetverbindung nutzbar sein, da sie keine Internetverbindung benötigt.	Die Anwendung kann bei deaktivierter Internetverbindung ausgeführt werden.	Must
NF-10	Wartbarkeit	Die Anwendung soll modular aufgebaut werden, sodass GUI, Datenverarbeitung, Visualisierung und Import/ Export voneinander getrennt sind.	Der Programmcode weist eine modulare Architektur auf und ist damit kein Monolith.	Should
NF-11	Wartbarkeit	Der Quellcode soll nachvollziehbar strukturiert und kommentiert sein.	Es existiert keine Klasse oder Funktion ohne Docstring.	Should
NF-12	Nachvollziehbarkeit	Durchgeführte Vorverarbeitungsschritte sollen in einem Logfile dokumentiert werden, um vorgenommene Veränderungen am Datensatz nachträglich nachvollziehen zu können.	Die Anwendung kann ein Logfile erzeugen, welches alle durchgeführten Vorverarbeitungsschritte enthält.	Could

Quelle: Eigene Darstellung.

3. Glossar

Tab. 4: Wichtige projektspezifische Abkürzungen und Begriffe

Begriff	Erläuterung
CIC-IDS2017	Intrusion Detection Datensatz, der vom kanadischen Institut für Cyber Security erzeugt und veröffentlicht wurde (Canadian Institute for Cybersecurity, 2018)
Flow-Datensatz	Gesamtheit aller geladenen Flow-Daten einschließlich ihrer Merkmale und Labels.
Feature	Ein einzelnes Merkmal bzw. eine Spalte eines Datensatzes, das Eigenschaften eines Netzwerk-Flows beschreibt.
Flow	Zusammengefasster Kommunikationsstrom von zwei Endgeräten in einem Netzwerk.
Label	Zielvariable eines Datensatzes, die die Klasse eines Netzwerk-Flows angibt, beispielsweise „BENIGN“ oder „Attack“.
ML-basiertes IDS	Intrusion Detection System, das Machine-Learning-Verfahren zur Erkennung von Angriffen einsetzt.
Train-Test-Split	Aufteilung eines Datensatzes in Trainings- und Testdaten zur späteren Entwicklung und Bewertung von Machine-Learning-Modellen.
Vorverarbeitung (Preprocessing)	Schritte zur Bereinigung und Vorbereitung eines Datensatzes für nachfolgende Analysen oder Machine-Learning-Verfahren.

Quelle: Eigene Darstellung.

Literaturverzeichnis

Canadian Institute for Cybersecurity. (2018). *IDS 2017 | Datasets | Research | Canadian Institute for Cybersecurity | UNB*. <https://www.unb.ca/cic/datasets/ids-2017.html>